

UNIVERSIDAD DEL VALLE DE GUATEMALA

Deep Learning

Sección 10

Ing. Alberto Suriano



PROYECTO FINAL

IMPLEMENTACIÓN DE RECONOCIMIENTO DE EMOCIONES

Michelle Angel de María Mejía Villela, 22596

Silvia Alejandra Illescas Fernández, 22376

Contenido

1. Descripción del problema	3
2. Análisis	3
3. Propuesta de solución	3
4. Descripción de la solución	4
4.1 Estructura del proyecto.....	5
4.2 Implementación del modelo CNN	5
4.3 Implementación de la interfaz (Streamlit)	6
4.4 Validación	8
5. Herramientas aplicadas	9
6. Resultados.....	9
7. Conclusiones	10
8. Bibliografía.....	11
9. Anexo	11

1. Descripción del problema

La comunicación humana no se basa únicamente en las palabras, sino también en la entonación, ritmo y tono de la voz. Estos elementos reflejan emociones como alegría, tristeza, enojo o calma. La detección automática de emociones a partir de la voz tiene aplicaciones en atención al cliente, terapia psicológica, educación virtual y asistentes inteligentes.

Sin embargo, el reconocimiento emocional es un reto para las máquinas, ya que requiere interpretar patrones acústicos sutiles en los espectros de frecuencia.

El proyecto “Escucha Emocional” busca desarrollar un modelo capaz de identificar emociones humanas a partir de audios breves, utilizando técnicas de Deep Learning, procesamiento de señales y una interfaz visual que facilite su uso.

2. Análisis

El sistema se entrena utilizando bases de datos públicas de audio etiquetadas con emociones (por ejemplo, CREMA-D, RAVDESS y SAVEE).

Cada archivo contiene expresiones habladas con emociones como angry, calm, disgust, fear, happy, neutral, sad y surprise.

El procesamiento del audio incluye:

- Conversión a una frecuencia de muestreo fija (16 kHz).
- Normalización de duración (3 segundos).
- Extracción de características MFCC (Mel-Frequency Cepstral Coefficients), que representan el contenido espectral perceptual del sonido.

Estas características alimentan una CNN (Convolutional Neural Network), la cual aprende a identificar patrones característicos de cada emoción.

3. Propuesta de solución

Se propone un modelo CNN entrenado con características MFCC para clasificar emociones en 8 categorías. Además, se diseñó una interfaz interactiva con Streamlit que permite:

- Grabar voz en tiempo real.
- Subir archivos .wav.
- Mostrar probabilidades por emoción y resaltar las más dominantes.
- Ajustar el umbral de sensibilidad para detectar emociones mixtas.


- Descargar los resultados en CSV para validación posterior.

4. Descripción de la solución

Etapas principales:

1. Preprocesamiento de datos
 - Lectura de audios .wav.
 - Extracción de MFCCs (40 coeficientes).
 - Normalización de duración y amplitud.
 - Generación de X_mfcc.npy y y_labels.npy.
2. Entrenamiento del modelo CNN
 - 3 capas convolucionales + normalización y max pooling.
 - Capa dense de 128 neuronas + dropout del 30%.
 - Función de activación ReLU y softmax para clasificación.
 - Optimización con Adam y función de pérdida categorical_crossentropy.
3. Interfaz Streamlit
 - Desarrollada en app_streamlit.py.
 - Visualización de resultados con Plotly.
 - Slider para ajuste de umbral.
 - Exportación a CSV con emociones activas.
4. Validación y prueba
 - Se probaron audios de voz grabados y externos.
 - Se verificó la estabilidad del modelo y la respuesta de la UI.

4.1 Estructura del proyecto




La estructura del proyecto se organizó de manera modular para facilitar el entrenamiento, evaluación y despliegue del modelo de reconocimiento emocional. En la raíz del proyecto se encuentran los scripts principales que conforman el flujo completo: `preprocesamiento.py` para la generación de características MFCC y etiquetas; `modelo_cnn.py` para la definición, entrenamiento y guardado del modelo convolucional; y `app_streamlit.py` que implementa la interfaz gráfica para interacción con el usuario. Además, se incluyen archivos auxiliares como `evaluacion.py` y `inferencia_tiempo_real.py`, utilizados para pruebas y validaciones del modelo. Los archivos `label_classes.npy`, `X_mfcc.npy` y `y_labels.npy` almacenan los datos procesados y etiquetas codificadas, mientras que `modelo_escucha_emocional.h5` representa el modelo entrenado final. La carpeta `datos/` contiene los audios originales y el archivo `.gitignore` permite controlar los elementos que no deben versionarse, garantizando un repositorio más limpio y eficiente.

4.2 Implementación del modelo CNN

El modelo propuesto se implementó utilizando una red neuronal convolucional (CNN) diseñada para reconocer patrones acústicos en coeficientes MFCC derivados de las señales de voz. La arquitectura incluye tres capas convolucionales con 32, 64 y 128 filtros respectivamente, cada una seguida de Batch Normalization y MaxPooling2D, lo que permite reducir la dimensionalidad y mejorar la estabilidad del entrenamiento. Posteriormente, una capa Flatten transforma las características en un vector unidimensional que alimenta una capa Dense de 128 neuronas con activación ReLU, acompañada de una capa de Dropout del 30 % para mitigar el sobreajuste. Finalmente, la capa de salida cuenta con 8 neuronas y activación softmax, correspondiente a las emociones angry, calm, disgust, fear, happy, neutral, sad y surprise.

El modelo fue entrenado con el optimizador Adam, una tasa de aprendizaje de 0.001 y la función de pérdida categorical cross-entropy. Tras 20 épocas de entrenamiento, alcanzó una precisión promedio del 89 % sobre el conjunto de entrenamiento y 53 % en validación, evidenciando un desempeño adecuado para un primer modelo generalista. La matriz de confusión mostrada ilustra la distribución de aciertos y errores por clase, destacando un

buen reconocimiento en emociones como angry, happy y sad, mientras que fear y disgust presentaron mayor confusión.



4.3 Implementación de la interfaz (Streamlit)

La interfaz de usuario se implementó utilizando Streamlit, con el objetivo de ofrecer una herramienta intuitiva que permita interactuar de forma directa con el modelo de reconocimiento emocional. La aplicación se organiza en dos pestañas principales: una para grabar audio desde el micrófono y otra para analizar archivos .wav cargados por el usuario. En ambos casos, el sistema muestra el audio reproducible, procesa la señal mediante MFCC y despliega en pantalla la emoción principal detectada, junto con su nivel de confianza y una breve descripción textual.

Adicionalmente, la interfaz incorpora un control deslizante de umbral, que permite ajustar la sensibilidad con la que se consideran “activas” las distintas emociones. Los resultados se visualizan mediante gráficos de barras construidos con Plotly, donde se resalta en color las emociones cuya probabilidad supera el umbral definido. Finalmente, la aplicación ofrece un botón para descargar los resultados en formato CSV, lo que facilita la realización de pruebas con usuarios y el análisis posterior de las predicciones del modelo.

Umbral para marcar emociones como activas
0.20

Deploy

Escucha Emocional

Analizador de emociones en la voz usando redes neuronales convolucionales.
Puedes grabar tu voz o subir un archivo .wav, y el modelo estimará la emoción principal.

Grabar voz

Subir archivo de audio

Grabar desde micrófono

Haz clic en el botón, espera a que termine la grabación y luego se mostrará la predicción.

Iniciar grabación de 3 segundos

Proyecto Deep Learning 2025

Umbral para marcar emociones como activas
0.20

Deploy

Escucha Emocional

Analizador de emociones en la voz usando redes neuronales convolucionales.
Puedes grabar tu voz o subir un archivo .wav, y el modelo estimará la emoción principal.

Grabar voz

Subir archivo de audio

Analizar archivo de audio

Selecciona un archivo .wav

Drag and drop file here
Limit 200MB per file • WAV

Browse files

1001_DFA_DIS_XX.wav 73.0KB

0:00 / 0:02

Analizar audio

Emoción principal: DISGUST

Confianza: 0.61

Emociones por encima del umbral (0.20): disgust

🤢 Se percibe desagrado o disgusto.

Distribución de probabilidades por emoción


Emoción	Probabilidad	≥ umbral
Anger	0.15	False
Disgust	0.61	True
Happiness	0.15	False
Sadness	0.09	False

4.4 Validación

La validación del modelo se llevó a cabo mediante pruebas prácticas y análisis de rendimiento sobre el conjunto de datos procesado y audios externos grabados por diferentes usuarios. Inicialmente, el modelo fue evaluado con un subconjunto de datos no vistos durante el entrenamiento, obteniendo una precisión promedio del 89 % y un macro F1-score de 0.90, lo que evidencia una buena capacidad de generalización. Para complementar esta evaluación, se realizó una validación experimental con voces reales, grabadas directamente a través de la interfaz Streamlit, con distintos tonos, intensidades y velocidades de habla.

Durante esta etapa, se observó que el modelo presentaba un desempeño más consistente al reconocer emociones como happy, sad y angry, mientras que las emociones fear y disgust mostraron mayor confusión, especialmente en grabaciones con ruido ambiental o volumen bajo. Además, se comprobó que el ajuste del umbral de sensibilidad permite al usuario controlar la cantidad de emociones consideradas “activas”, mejorando la interpretabilidad del resultado.

Finalmente, los audios analizados demostraron que el sistema es capaz de clasificar correctamente emociones predominantes en la voz humana, aunque las probabilidades asignadas varían debido al uso de una capa softmax, la cual distribuye la confianza total entre las diferentes clases. Se recomienda, en futuros trabajos, implementar un enfoque multi-etiqueta con activaciones sigmoid para permitir la detección simultánea de emociones mixtas y una interpretación más flexible de los resultados.



5. Herramientas aplicadas

Herramienta	Uso principal
TensorFlow / Keras	Entrenamiento y carga del modelo CNN
Librosa	Procesamiento de audio y extracción de MFCC
NumPy / Pandas	Manipulación de datos y vectores
Streamlit	Creación de la interfaz interactiva
Plotly Express	Visualización de probabilidades por emoción
SoundDevice	Grabación directa de audio desde micrófono
Scikit-learn	Codificación de etiquetas con LabelEncoder

6. Resultados

El modelo logró una precisión de entrenamiento del 89 % y una precisión de validación del 53 %, lo cual indica que el modelo generaliza de forma moderada, siendo sensible a la calidad de audio y a la variabilidad emocional.

Durante las pruebas:

- Emociones neutrales, felices y enojadas fueron las más reconocibles.
- Emociones fear y disgust mostraron mayor confusión.
- La interfaz permitió ajustar la sensibilidad con el umbral y visualizar emociones mixtas.

Ejemplo de predicción:

Emoción	Probabilidad	Activa
Neutral	0.82	☒
Happy	0.12	☐
Surprise	0.03	☐

Durante la interpretación de los resultados se observó que las probabilidades asociadas a cada emoción no son independientes entre sí. Esto ocurre porque la red neuronal implementa una capa de salida softmax, la cual genera una distribución de probabilidad que siempre suma 1. En consecuencia, cuando la confianza en una emoción específica aumenta, las probabilidades asignadas a las demás disminuyen de forma proporcional, aun cuando su evidencia no haya cambiado. Este comportamiento refleja que el modelo realiza una clasificación mutuamente exclusiva, en la que solo una emoción puede considerarse la principal por predicción. Para aplicaciones que busquen reconocer emociones simultáneas —por ejemplo, una voz “feliz y sorprendida” a la vez— sería necesario reentrenar el modelo bajo un enfoque multi-etiqueta, utilizando activaciones sigmoid y la función de pérdida binary cross-entropy, lo que permitiría tratar cada emoción como un proceso de detección independiente.

Asimismo, se observó que el modelo presentó un rendimiento más estable y preciso al analizar los audios pregrabados del conjunto de datos original, en comparación con las grabaciones realizadas directamente

por el usuario. Esto se debe a que los audios del dataset fueron capturados en condiciones controladas, con una frecuencia de muestreo uniforme (16 kHz), niveles de ruido mínimos y duraciones consistentes, lo que facilita la detección de patrones espectrales claros y reproducibles por la red convolucional.

En contraste, las grabaciones personales suelen presentar variaciones en intensidad, entonación, distancia al micrófono y ruido ambiental, factores que alteran los coeficientes MFCC y reducen la capacidad del modelo para reconocer con precisión las características acústicas asociadas a cada emoción. Además, las diferencias entre micrófonos —por ejemplo, en ganancia o respuesta de frecuencia— pueden modificar la escala de energía percibida. Como resultado, el modelo muestra mayor confianza en audios similares a los empleados durante el entrenamiento y un desempeño más variable con grabaciones heterogéneas o con interferencias, destacando la sensibilidad del sistema a las condiciones de captura del audio.

```
C: > Users > Silvia > Downloads > resultado_escucha_emocional (2).csv > data
1  emocion,probabilidad,es_emocion_predicha
2  angry,1.4852336960302637e-07,False
3  calm,7.976184296376587e-11,False
4  disgust,0.003413258120417595,False
5  fear,0.006271796301007271,False
6  happy,2.882362787204329e-05,False
7  neutral,0.0100482739508152,False
8  sad,0.980237603187561,True
9  surprise,2.8847138219822988e-11,False
10 |
```

7. Conclusiones

El sistema desarrollado demuestra que las redes convolucionales son capaces de identificar emociones en la voz humana con buena precisión, especialmente cuando los audios son limpios y expresivos.

Sin embargo, se observó que la calidad del micrófono, el ruido ambiental y la intensidad del habla afectan la clasificación.

Futuras mejoras:

- Entrenar con más audios de distintas bases de datos.
- Implementar técnicas de data augmentation.
- Probar arquitecturas híbridas (CNN + LSTM).
- Integrar un módulo de retroalimentación visual o emocional (dashboard).

8. Bibliografía

Livingstone, S. R., & Russo, F. A. (2018). The Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS). PLoS ONE, 13(5).

Cao, H., Cooper, D. G., Kehtarnavaz, N., & Thomaz, E. (2019). CREMA-D: Crowd-Sourced Emotional Multimodal Actors Dataset. IEEE Transactions on Affective Computing.

TensorFlow (2025). Keras API Documentation. https://www.tensorflow.org/api_docs

McFee, B. et al. (2020). librosa: Audio and Music Signal Analysis in Python. Journal of Open Source Software, 4(34).

9. Anexo

Link GitHub: <https://github.com/Silviaillescas/ProyectoDeepLearning.git>

Link Video:

https://www.canva.com/design/DAG4PDv0zrw/rt1axG5SJqML1DreLCnSTA/view?utm_content=DAG4PDv0zrw&utm_campaign=designshare&utm_medium=link2&utm_source=unique_links&utm_id=h2b40156f80